

第二十届中国研究生电子设计竞赛

技术论文

基于微光纤的仿生光子触觉皮肤的设计与应用

Design and Application of a Bio-inspired
Photonic Haptic Skin based on Optical
Microfibers

参赛单位:

队伍名称: 盛夏光年

指导老师:

参赛队员:

完成时间: 2025 年 6 月 19 日

摘 要

触觉传感器技术作为我国面临的35项“卡脖子技术”之一,对国民经济和社会发展至关重要。受人体皮肤触觉感知的启发,开展具有高灵敏感知能力的柔性触觉传感器研究是目前国际触觉传感器研究的热点。而仿生皮肤传感器在机器人与人机交互领域起着至关重要的作用。这些传感器通过模拟人类皮肤的触觉、温度和压力感知能力,使机器人能够实时检测环境变化并做出精准响应,从而提升操作安全性和交互自然性。目前,电子仿生皮肤技术表现出了良好的性能,但面临设计复杂、生产困难、信号准确性和数据可靠性等挑战。随着柔性光电技术的发展,微光纤(Optical Microfiber,OMF)因其具有灵敏度高、响应快、抗电磁干扰等优势,成为组装仿生光子皮肤的重要部分。该技术利用微光纤结构的光场调制特性,将外力作用转化为光强、波长或相位的变化,结合柔性基底与微加工工艺,赋予器件优异的可拉伸性与环境适应性。

因此,本论文提出了一种基于 OMF 的仿生光子皮肤传感器,其加入了柱状微结构环绕光纤的新颖设计,通过模仿人类皮肤的力学感知机制,实现了高灵敏度、多模态触觉信号的检测。该仿生皮肤采用 Eco-flex 与 Dragon-skin 弹性体材料作为柔性基底,并使用聚二甲基硅氧烷(PDMS)对围绕在同行或同列的微柱间形成各个通道的 OMF 进行封装。通过研究,基于此结构的仿生皮肤展示出了较高的力灵敏度(0.827 N^{-1})。通过在仿生皮肤上进行按压与滑动,将传感器导出的数据通过卷积神经网络(CNN)模型进行训练、识别以及预测,实现了对手写字符的高准确率识别以及在二维平面上的高分辨率的力与位置的识别。对仿生皮肤表面手写输入字符的识别准确率达到 97.20%。在二维平面的位置预测分辨率达到 $4\mu\text{m}$,而法向力的力预测分辨率达到 15mN,展现出了较好的分布式传感能力。此外,设计了基于 LabVIEW 平台的人机交互界面,用于演示传感器对于手写文字的识别和力与空间分布的响应。这一创新解决方案在光学触觉仿生皮肤、机器人和其他相关领域具有广阔的应用前景。

关键词: 光纤传感器; 仿生皮肤; 神经网络; 文字识别; 分布式传感

Abstract

The tactile sensor technology, as one of the 35 "neck-bottleneck technologies" facing China, plays a critical role in national economic and social development. Inspired by the human skin's tactile perception mechanisms, research on flexible tactile sensors with high sensitivity has become a global focus. Bio-inspired skin sensors are pivotal in robotics and human-machine interaction, enabling real-time detection of environmental changes and precise responses by mimicking human skin's ability to sense touch, temperature, and pressure. While electronic bio-inspired skin technologies demonstrate excellent performance, they still face challenges such as design complexity, manufacturing difficulties, signal accuracy, and data reliability. With advancements in flexible optoelectronics, optical microfibers (OMF) have emerged as key components for bio-inspired photonic skins due to their high sensitivity, fast response, and electromagnetic interference resistance. This technology leverages the optical field modulation properties of microfiber structures to convert external forces into changes in light intensity, wavelength, or phase, combined with flexible substrates and microfabrication techniques to achieve stretchability and environmental adaptability.

This paper proposes a bio-inspired photonic skin sensor based on OMF, incorporating a novel design of columnar microstructures surrounding the fibers to emulate human tactile sensing mechanisms. The sensor achieves high-sensitivity, multimodal tactile detection. The bio-inspired skin uses Eco-flex and Dragon-skin elastomers as flexible substrates and employs PDMS encapsulation for the OMF channels between microcolumns. The developed structure demonstrates a high force sensitivity of 0.827 N^{-1} , with short response and recovery times. Through experiments involving pressing and sliding on the skin surface, sensor data were processed using a Convolutional Neural Network (CNN) for training, recognition, and prediction, achieving 97.20% accuracy in handwritten character recognition and submicron resolution in 2D spatial force and position detection ($4 \text{ }\mu\text{m}$ spatial resolution and 15 mN force resolution). A human-machine interface based on LabVIEW was designed to demonstrate real-time recognition of handwritten inputs and force distribution responses. This innovative solution has significant application potential in optical tactile bio-inspired skins, robotics, and related fields.

Key words: Optical fiber sensor; Bionic skin; Neural network; Characters recognition; Distribution sensing

目 录

摘 要.....	2
Abstract.....	3
第 1 章 作品难点与创新.....	1
1.1 作品难点.....	1
1.2 作品创新点.....	2
第 2 章 方案论证与设计.....	3
2.1 系统整体设计.....	3
2.2 传感器结构设计.....	3
2.3 实验系统搭建.....	4
2.4 智能识别.....	5
第 3 章 原理分析.....	6
3.1 长腰区微光纤原理.....	6
3.2 2D CNN-BiLSTM 模型原理.....	8
第 4 章 软件设计与流程.....	11
4.1 整体架构分析.....	11
4.2 算法结构.....	11
4.2.1 硬件和软件配置.....	11
4.2.2 模型参数设置.....	11
4.2.3 算法逻辑.....	12
4.3 可视化设计.....	15
第 5 章 系统测试与分析.....	17
5.1 传感器力学性能测试.....	17
5.2 分布式传感测试.....	19
5.2.1 空间分辨率测试.....	19
5.2.2 手指滑动测试.....	21
5.3 UI 功能测试.....	23
第 6 章 总结与规划.....	25
6.1 作品总结.....	25

6.2 未来规划	25
参考文献	26

第 1 章 作品难点与创新

1.1 作品难点

近年来，柔性触觉传感器在电子皮肤、人机交互以及健康检测等领域均展现出了广阔的应用前景。^[1]目前常见的电子触觉仿生皮肤虽然取得了一定的成果，但仍然存在一些显著的缺点，包括制造成本高、寄生效应、电路复杂、信号串扰等，可能会限制其在实际上应用的问题。本作品采用微光纤制作触觉传感器，其使用光传输可以克服相关的困难，具有尺寸小、柔韧性强、灵敏度高、抗电磁干扰、易于制作等优点^[2]。

文字识别主要基于按压式和滑动式两种模式实现。按压式识别相对简单，通过对仿生皮肤传感区域施加不同位置和压力的按压动作来完成识别，其关键在于精确识别每个按压点的位置。滑动式识别则更为复杂，需要在仿生皮肤表面进行书写滑动，要求传感器能够高精度地追踪手指书写字符的滑动轨迹。这涉及到分布式传感阵列的优化设计、灵敏度的精细调节以及实时信号处理算法。因此，为实现准确的滑动轨迹识别，传感器必须具备极高的空间分辨率和快速的响应速度，以确保能够连续、精准地捕捉书写过程中细微的轨迹变化^[3]。

为了实现二维平面上的分布式传感，需要制备超长腰微光纤。微光纤锥段的模间能量转换和腰段的散射损耗是影响光纤透过率的主要因素。因此需要设计合适的参数与拉制工艺使得微光纤保持较高的透过率。此外，微光纤由于其较小的直径，因此容易发生微光纤的断裂损坏问题，需要通过合适的封装结构使得传感器更为稳定。此外，封装的厚度与传感器的灵敏度成反比，所以需要在其中找到平衡，使得两者能够兼顾。

在结构设计之外，实现滑动式文字识别还需要开发能够有效处理连续轨迹数据并与预定义字符模型匹配的智能算法。这类算法需要具备高效的数据处理能力和精准的模式识别性能。当前文字信号处理领域主要采用卷积神经网络（CNN）作为解决方案，但其存在若干局限性：首先，尽管一维 CNN 能够处理序列数据，但其训练过程依赖大量标注数据；其次，深层 CNN 网络在训练过程中易出现梯度消失或梯度爆炸等问题；此外，面对小规模数据集时，CNN 模型容易发生过拟合现象，严重影响模型的泛化能力。这些技术瓶颈制约了 CNN 在滑动式文字识别应用中的性能表现。

因此我们需要设计一个基于 OMF 结构的触觉仿生皮肤传感器系统，采用柔性聚合物的封装结构，引入具有强大的处理和记忆长距离依赖关系能力的

CNN-BiLSTM 算法,实现对传感器获取的字符模型数据信号进行预测识别。为了将整个系统设计进行可视化展示,我们设计了一个具有传感器采集数据、模型训练、模型预测准确率功能的集成化界面。

1.2 作品创新点

本作品提出一种受人体皮肤结构启发的基于微光纤的仿生光子触觉皮肤 (Bio-inspired Photonic Haptic Skin based on Optical Microfibers, BPHS), 以解决机器人集成光学皮肤中触感灵敏度和传感范围不能兼顾的问题,利用多通道的光子皮肤进行仿生触觉传感, 其创新点如下:

(1) 表面微柱结构: 在受到外界压力作用时, 传感器表面的微柱结构会随压力的增加逐渐变形, 微光纤的弯曲程度也会随之增加。由于微光纤弯曲程度的增加会改变能量场的占比变化, 进而影响输出信号的强度。

(2) 仿生多层封装: 使用 Eco-flex 与 Dragon-skin 弹性体材料作为柔性衬底, 并使用PDMS封装微光纤, 模拟真实人体皮肤的结构, 使得仿生皮肤的杨氏模量与厚度接近于真实人体皮肤。

(3) 多通道设计: 本传感单元采用 S 形微光纤组成的 8 通道阵列结构, 具有出色的同步响应性, 使得分布面积更大, 8 路信号同时增强了信号识别的容错率与准确度。

(4) 可视化界面设计: 引入 CNN-BiLSTM 算法, 辅助识别手写字符与力的大小位置的分布, 并设计了基于 LabVIEW 平台的人机界面, 将后台数据处理与前端展示集为一体, 将实时波形绘制, 神经网络模型训练、预测以及实时准确率展现出来, 实现手写文字识别与力的空间分布式传感的可视化。

第 2 章 方案论证与设计

2.1 系统整体设计

人体皮肤配备有丰富的触觉感受器，不仅能识别刺激的位置，还能感知相应的力的信息。^[4]当外部物理刺激作用于皮肤时，感觉受体检测并把机械刺激转化为电信号。这些信号随后通过神经纤维传至大脑，使人能够感知刺激的位置和力的大小^[5]。因此，我们模拟人类对于外部刺激的感知设计了光子皮肤的传感系统。其可以通过模拟皮肤独特的生物微结构和触觉传导机制，将触觉机械按压、滑动的刺激转换为以透射光输出强度变化的形式，能够有效地检测静压、动压、振动等机械刺激。首先，光源为光纤传感器提供光激励，当传感器受到外力，其输出光强的变化被光电检测器检测到，并将其转化为电信号的变化，而神经网络模型则模拟了人的大脑对电信号进行处理与分析，最后呈现在计算机的人机交互界面上。通过搭建该系统，可以有效地模拟人类真实情况下受到外部刺激时大脑处理的全部过程。




图 2-1 系统整体设计流程图

2.2 传感器结构设计

本作品设计的柔性触觉传感器通过模仿人类皮肤的触觉特性实现对二维分布力的精准识别，它的核心结构由衬底层和 PDMS 薄膜封装的微纳光纤组成，以此实现将外部力相关的触觉刺激，例如压力和振动，转化为光纤变形和弯曲。

传感器的制作流程如下：首先在 3D 打印制备的模具中倒入 1:1 比例调制的 Dragon-skin 硅胶液，将其放置于加热箱中 50℃加热 10 min，待其固化冷却后，

形成约 3mm 厚的第一层衬底；再将 1:1 调制的 Eco-flex 硅胶液倒入模具中，将其放置于加热箱中 50℃加热 15 min，形成约 600μm 厚的第二层衬底；然后将制备的 PDMS 微柱置于衬底上，将制备的微光纤以 S 形依次纵横排列绕过微柱；最后再在微光纤上浇筑一层 PDMS 溶液，放入加热箱 60℃加热 60min，待其固化后，传感器制作完成。BPHS 的制作流程如图 2-2 所示。




图 2-2 BPHS 的制作流程图

2.3 实验系统搭建

本实验搭建的实验装置如图 2-3 所示。由宽带光源发出的光经由一个 1*8 的光分束器形成八路信号，分别接入传感器的八个输入端；再将传感器置于力学测试平台上，传感器输出的光信号被多通道光电探测器接受，并将其转换为电信号；高速数据采集板从光电探测器收集信号，并将其传输到计算机进行实时分析。其中，力学测试平台由 Z 轴升降台和 XY 二维位移台，以及六轴力传感器组成。六轴力传感器输出的力值可以通过上位机软件进行采集，通过在轴向上垂直按压传感单元，通过观察上位机输出的强度变化从而定量分析传感单元在静态刺激下的响应特性，从而进行数值标定。




图 2-3 实验系统图

2.4 算法设计

虽然通过实验数据波形已可以通过推理得知所测文字、字母符号，但人工识别具有疲劳期、耗时慢，这将会导致出错率增加、效率低等的问题，于是我们寻求通过智能算法实现 符号的快速识别、精准检测。

常见的序列预测算法有一维 CNN、递归神经网络（RNN）、生成对抗网络（GAN）等，但一维 CNN 需要设计合适的卷积核和层数且对于捕捉长时间依赖关系差，RNN 容易出现梯度消失和梯度爆炸问题，GAN 需要精细调参且生成的序列可能不完全符合实际数据分布。

LSTM记忆网络采用门控机制解决了梯度弥散问题，可以有效地捕捉和处理长时间依赖关系，对于可变长度的序列具有很好的适应性，可以通过堆叠多个 LSTM 层或在不同层之间共享权重的方式来进行多任务学习，LSTM 可以有效地学习序列中的时序模式和趋势，但是LSTM的方向性仅仅微正向处理序列，参数量较少，只适合单相以来任务。

所以我们选择是用BiLSTM记忆网络，它弥补了LSTM的缺点，可以正向+反向双通道处理，参数量是LSTM的2倍，在上下文任务中性能表现更优。

总之，LSTM 网络通过门控机制和记忆单元的设计，克服了传统循环神经网络的一些缺点，具有较好的长时间依赖建模能力和适应可变长度序列的能力，适用于预测、分类、生成等各种时间序列分析任务，BiLSTM比单向LSTM更全面性能更优，显著的提升准确率在处理时间序列数据中有明显的优势，继而可以通过BiLSTM 记忆网络和2D-CNN卷积神经网络的深度学习模型实现对字符的智能识别。

第 3 章 原理分析

3.1 长腰区微光纤原理

利用单模光纤熔融拉锥可以得到非绝热锥形结构的 OMF，为实现仿生皮肤的分布式传感，制备了腰长约 8cm、直径约 10 μm 的长腰区微光纤，长腰区微光纤的结构如图 3-1 所示：




图 3-1 双模干涉式 OMF 结构示意图

为制备超长腰微光纤，采用“火焰静止、台子移动”的改进“火焰刷”方法进行加热拉锥^[6]。具体过程为：首先以 0.08 mm/s 的速度向两侧拉伸光纤，直至单边拉伸长度达到 0.5 mm；随后，平移台以 2 mm/s 的速度同向扫描运动，同时拉伸台继续以 0.08 mm/s 的速度相向运动，使有效火焰区域随拉伸长度线性变化，从而实现对光纤细腰区域的连续可控拉伸。该工艺中，光纤腰长与拉伸长度的关系可通过公式（3-1）定义扫描周期，其中参数 $a = 0.5$ ，以精确调控拉锥过程中的动态行为。

$$P = P_0 \times (1 + 4a \frac{v_1}{v_2}) \quad (3-1)$$

P_0 是上一个扫描周期，微光纤腰长可以表述为公式（3-2）：

$$L_w = P \times \frac{v_2}{2} \quad (3-2)$$

与普通光纤相比，微光纤的直径在波长或亚波长量级，因此可将整体光纤看做纤芯，外部环境为包层，因此微光纤的折射率分布呈现阶跃式分布。^[7]其剖面折射率的分布示意图如图 3-2 所示。




图 3-2 微光纤剖面折射率分布示意图

微光纤波导折射率分布可表示为式（3-3）：

$$n(r) = \begin{cases} n_1 & 0 < r < R \\ n_2 & R \leq r < \infty \end{cases} \quad (3-3)$$

式中 R 为微光纤的半径大小， n_1 为纤芯折射率， n_2 为包层（空气或是液体环境）折射率。我们将微光纤看作无源且非耗散的材质，即微光纤中的光传播可视为无损耗且无增益，在这种假设条件下，电磁波传输满足的 Maxwell 方程组可简化为如（3-4）的 Helmholtz 方程组形式^[8]：

$$\begin{cases} (\nabla^2 + n^2 k^2 - \beta^2) \vec{E} = 0 \\ (\nabla^2 + n^2 k^2 - \beta^2) \vec{H} = 0 \end{cases} \quad (3-4)$$

其中， ∇^2 为横向拉普拉斯算符， n 代表折射率，波矢 $k = 2\pi / \lambda$ 代表光的波长， β 则代表纵向传播常数。

在光纤弯曲的情况下，波导传输方向的变化是不可避免的，可能导致弯曲损耗或模式耦合^[9]。实验证明，熔融锥形 OMF 表现出极佳的均匀性，缺陷极少，火焰熔融拉锥实验如图 3-4、图 3-5 所示。这些纤维可以承受超过 5% 的拉伸应变而不会断裂，其平均拉伸强度高达 6GPa，显著超过典型单模石英光纤的 3GPa 拉伸强度。值得注意的是，即使弯曲达到 180°，OMF 仍保持稳固的机械性能。理论计算表明，对于亚波长直径的 OMF，在弯曲半径在数十微米范围内时，弯曲损耗非常低，仅为 0.01dB/mm。



图 3-4 拉锥实验系统示意图




图 3-5 火焰刷法制备长腰区 OMF

3.2 CNN-BiLSTM 模型原理

本研究构建了一种结合卷积神经网络（2D CNN）与双向长短期记忆网络（Bi-LSTM）的深度学习模型，首先2D CNN是一种基于二维卷积神经网络的深度学习模型，用于从柔性微光纤阵列采集的光谱数据中提取有效特征，以实现后续的按压位置与压力大小的多任务预测。整个模型架构如图 3-6 所示，由输入层、两组卷积与池化模块、全连接层以及输出层组成，具备清晰的层级结构与高效的特征提取能力。




图3-6 2D CNN结构原理图

输入数据维度为 4500×8 ，对应于 4500 组样本、每组 8 通道光纤数据。在预处理阶段，数据被划分为训练集（80%）、验证集（10%）和测试集（10%），以确保模型具备良好的泛化能力。

第一阶段为特征提取模块，由两个连续的二维卷积层（Conv2D）与最大池

化层 (MaxPool2D) 组成。第一个卷积层采用 16 个卷积核对输入矩阵进行特征提取, 并通过 ReLU 激活函数引入非线性。池化操作降低了特征图的空间尺寸, 减小参数量的同时保留关键信息。第二组卷积与池化操作则进一步提取深层局部特征, 卷积核数量增加至 32, 以增强特征表达能力。

特征图在经过两组卷积与池化操作后被展平 (Flatten), 转换为一维向量, 便于送入后续的全连接层。接着通过两个全连接层 (fully connected layers) 进行特征融合与映射, 第一全连接层将高维特征压缩至 512 维, 第二层进一步降维至 256 维, 形成最终的特征表示。

输出层为一个线性映射层, 维度为 1×9 , 对应于三个任务的联合预测: 按压位置的 x 坐标、y 坐标, 以及压力的强度。

整体模型结构紧凑, 具备较强的特征提取与表达能力, 适合处理微光纤阵列采集的二维光谱数据。通过卷积提取空间特征、全连接层进行融合与压缩, 再通过线性输出实现可以对按压行为实现高精度识别。

接着通过 2D-CNN 模型卷积特征图经展平和映射后送入 BiLSTM 模块, 将进一步挖掘时间序列中的前向与反向依赖关系。BiLSTM 包含两个 LSTM 子网络, 一个沿时间正向处理序列, 提取过去到当前的特征; 另一个则反向处理序列, 关注当前与未来的关联, 如图 3-7 所示。最终两个方向的特征被融合用于输出预测。这种结构不仅提高了模型对复杂特征的理解能力, 还能显著提升对按压坐标和力度大小的回归精度。




图3-7 BiLSTM结构原理图

具体算法如下:

其中 LSTM 单元由输入门 (input gate)、遗忘门 (forget gate)、输出门 (output gate) 和细胞状态 (cell state) 组成。其主要公式如下:

输入门:

$$i_t = \sigma(W_{xi}x_t + W_{hi}h_{t-1} + W_{ci}c_{t-1} + b_i) \quad (3-5)$$

遗忘门:

$$f_t = \sigma(W_{xf}x_t + W_{hf}h_{t-1} + W_{cf}c_{t-1} + b_f) \quad (3-6)$$

细胞状态更新:

$$\tilde{c}_t = \tanh(W_{xc}x_t + W_{hc}h_{t-1} + b_c) \quad (3-7)$$

细胞状态更新:

$$c_t = f_t \cdot c_{t-1} + i_t \cdot \tilde{c}_t \quad (3-8)$$

输出门:

$$o_t = \sigma(W_{xo}x_t + W_{ho}h_{t-1} + W_{co}c_t + b_o) \quad (3-9)$$

隐状态更新:

$$h_t = o_t \cdot \tanh(c_t) \quad (3-10)$$

其中, x_t 是时间步 t 的输入, h_{t-1} 是上一个时间步的隐状态, c_{t-1} 是上一个时间步的细胞状态, i_t 、 f_t 、 $\tilde{c}_t$ 、 c_t 、 o_t 分别是输入门、遗忘门、细胞状态、输出门和隐状态, W 是模型参数, σ 是 sigmoid 函数, $\tanh$ 是双曲正切函数。

BiLSTM 通过双向信息流, 可以更好地捕捉序列中的上下文信息, 提高模型性能^[10]。2D CNN-BiLSTM 模型通过卷积神经网络提取空间特征, 通过双向 LSTM 捕捉时序信息的双重优势, 使其非常适合处理复杂时间和空间数据, 能够有效地从时空维度联合建模, 精确预测按压位置和力度。

第 4 章 软件设计与流程

4.1 整体架构分析

Python 作为一种简洁、易学且功能强大的编程语言，为人工智能算法的开发提供了丰富的库和框架支持。我们用 Python 作为算法验证和软件开发工具，搭载 PyTorch 与 NVIDIA 显卡进行了模型计算，并通过 LabVIEW 实现了数据、训练的可视化显示。

4.2 算法结构

4.2.1 硬件和软件配置

为了实现算法验证，我们的硬件参数如表 4-1：

表4-1 硬件参数	
电脑品牌	机械革命 耀世 15pro
CPU	13th Gen Intel(R) Core(TM) i9-13900HX
显卡	RTX 4060
分辨率	2540×1640
硬盘容量	1TB

软件参数如表 4-2：

表4-2 软件参数	
开发工具	Visual Studio Code
Python 版本	3.12.7
CUDA 版本	12.8
PyTorch 版本	2.6.0
测试平台	win11

4.2.2 模型参数设置

模型设置：三个卷积层来处理输入 csv 数据，堆叠 2 层 BiLSTM,输出后使用三个独立的全连接层分别预测 X 坐标、Y 坐标和力的大小。在训练过程中，使用了 Adam 优化器来更新整个网络的所有参数，学习率为 0.0001，批次为 32。损失函数采用 L1 Loss（平均绝对误差），并采用加权组合的方式对三个任务进行联合优化。其中，X 和 Y 坐标的损失各占 0.4 的权重，而力的大小占 0.2 的权重。这种加权方式有助于平衡不同任务之间的梯度影响，使模型更关注坐标的精确预测。

模型性能评估：模型在测试集上的表现通过以下指标进行评估。

(1) MSE（均方误差）：衡量预测值与真实值之间的平均平方误差。

- (2) RMSE（均方根误差）：更直观地反映误差的实际量级。
- (3) R^2 决定系数：评估模型解释目标变量变异的能力。
- (4) 准确率（Accuracy）：计算预测坐标与真实坐标的欧氏距离小于特定阈值（如 1 单位）的比例。

4.2.3 算法逻辑

2D CNN-BiLSTM算法将输入的一维信号首先经过三层堆叠的卷积模块处理。每一层卷积模块由一维卷积层（Conv1D）、ReLU激活函数和最大池化层（MaxPool1D）组成，依次进行特征提取和空间下采样操作。通过这些操作，模型能够有效捕捉csv数据中的局部模式，并逐步降低特征的空间维度，从而形成更具代表性的高层特征表达。最终输出的特征张量被展平后送入一个全连接层，进一步压缩和提炼特征表示。

随后，全连接层的输出被重构为序列形式，作为双向LSTM网络的输入。该LSTM层在时间步维度上双向建模，能够同时利用前向和后向的时序信息，增强模型对输入序列上下文的理解能力。LSTM的最终隐藏状态被用于生成三个独立的输出头，分别对应X坐标、Y坐标以及力的大小的预测值。

整个模型的训练过程采用加权平均绝对误差损失函数。优化器选用Adam算法，以0.0001的学习率进行参数更新。训练过程中还引入了验证集监控机制，当验证损失达到历史最低时保存当前模型参数，以确保获得最佳性能。

模型评估阶段，使用反归一化方法将预测结果还原到原始尺度，并计算X、Y坐标和力度量的均方误差（MSE）、均方根误差（RMSE）以及 R^2 决定系数等指标，以全面衡量模型的预测精度。此外，还通过散点图、坐标对比图和三维柱状图等形式直观展示预测结果与真实值之间的差异。

图 4-1为算法流程图，图 4-2 展示了数据集构建部分代码，图 4-3 展示了模型训练逻辑部分代码，图 4-4 展示了模型评估及其可视化部分代码。




图 4-1 LSTM 算法流程图

```
import matplotlib
matplotlib.use('Agg') # 强制使用非交互式后端

import os
import pandas as pd
import numpy as np
import torch
import torch.nn as nn
import torch.optim as optim
import torch.nn.functional as F
from torch.utils.data import Dataset, DataLoader, Subset
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import MinMaxScaler
from sklearn.metrics import mean_squared_error, r2_score
import matplotlib.pyplot as plt
import seaborn as sns
from mpl_toolkits.mplot3d import Axes3D

# Custom Dataset Class
class UnifiedDataset(Dataset):
    def __init__(self, data_dir):
        self.data_dir = data_dir
        self.file_list = [f for f in os.listdir(data_dir) if f.endswith('.csv')]
        self.data = []
        self.labels_x = []
        self.labels_y = []
        self.labels_mag = []

        # Load all data
        for filename in self.file_list:
            x, y, mag = map(float, filename[:-4].split(','))
            file_path = os.path.join(data_dir, filename)
            df = pd.read_csv(file_path, header=None)
            spectral_data = df.values.flatten().astype(np.float32)

            self.data.append(spectral_data)
            self.labels_x.append(x)
            self.labels_y.append(y)
            self.labels_mag.append(mag)

        # Convert to numpy arrays
        self.data = np.array(self.data)
        self.labels_x = np.array(self.labels_x)
        self.labels_y = np.array(self.labels_y)
        self.labels_mag = np.array(self.labels_mag)
```

图 4-2 算法流程图

```
def train_model(model, train_loader, val_loader, test_loader, scalars, epochs=100, device='cpu'):
    x_scaler, y_scaler, mag_scaler = scalars
    criterion = nn.L1Loss()
    optimizer = optim.Adam(model.parameters(), lr=1e-4)
    model.to(device)

    for epoch in range(epochs):
        model.train()
        total_loss = 0.0
        for spectra, x, y, mag in train_loader:
            spectra = spectra.to(device)
            x, y, mag = x.to(device), y.to(device), mag.to(device)
            optimizer.zero_grad()
            pred_x, pred_y, pred_mag = model(spectra)
            loss = 0.4 * criterion(pred_x, x) + 0.4 * criterion(pred_y, y) + 0.2 * criterion(pred_mag, mag)
            loss.backward()
            optimizer.step()
            total_loss += loss.item()

        val_loss = 0.0
        model.eval()
        with torch.no_grad():
            for spectra, x, y, mag in val_loader:
                spectra = spectra.to(device)
                x, y, mag = x.to(device), y.to(device), mag.to(device)
                pred_x, pred_y, pred_mag = model(spectra)
                val_loss += 0.4 * criterion(pred_x, x) + 0.4 * criterion(pred_y, y) + 0.2 * criterion(pred_mag, mag)

        print(
            f'Epoch {epoch + 1}/{epochs} | Train Loss: {total_loss / len(train_loader):.4f} | Val Loss: {val_loss / len(val_loader):.4f}')

    print("\nFinal Test Set Evaluation:")
    evaluate_model(model, test_loader, scalars, device)
```

图 4-3 数据集构建部分

```
def evaluate_model(model, loader, scalers, device='cpu'):
    x_scaler, y_scaler, mag_scaler = scalers
    model.eval()
    true_x, true_y, true_mag = [], [], []
    pred_x, pred_y, pred_mag = [], [], []

    with torch.no_grad():
        for spectra, x, y, mag in loader:
            spectra = spectra.to(device)
            outputs = model(spectra)

            px = x_scaler.inverse_transform(outputs[0].cpu().numpy())
            py = y_scaler.inverse_transform(outputs[1].cpu().numpy())
            pm = mag_scaler.inverse_transform(outputs[2].cpu().numpy())

            tx = x_scaler.inverse_transform(x.numpy())
            ty = y_scaler.inverse_transform(y.numpy())
            tm = mag_scaler.inverse_transform(mag.numpy())

            pred_x.extend(px.flatten())
            pred_y.extend(py.flatten())
            pred_mag.extend(pm.flatten())
            true_x.extend(tx.flatten())
            true_y.extend(ty.flatten())
            true_mag.extend(tm.flatten())

    true_x = np.array(true_x)
    pred_x = np.array(pred_x)
    true_y = np.array(true_y)
    pred_y = np.array(pred_y)
    true_mag = np.array(true_mag)
    pred_mag = np.array(pred_mag)

    mse_x = mean_squared_error(true_x, pred_x)
    mse_y = mean_squared_error(true_y, pred_y)
    mse_mag = mean_squared_error(true_mag, pred_mag)

    distances = np.sqrt((true_x - pred_x) ** 2 + (true_y - pred_y) ** 2)
    accuracy = np.mean(distances < 1.0) * 100

    print(f"\nEvaluation Results:")
    print(f"MSE for X Coordinate: {mse_x:.6f}, MSE for Y Coordinate: {mse_y:.6f}, MSE for Magnitude: {mse_mag:.6f}")
    print(f"Prediction Accuracy (Error <1 unit): {accuracy:.4f}%")

    plot_scatter(true_x, pred_x, "X Coordinate Prediction")
    plot_scatter(true_y, pred_y, "Y Coordinate Prediction")
    plot_scatter(true_mag, pred_mag, "Magnitude Prediction")
    plot_coordinates(true_x, true_y, pred_x, pred_y)
    plot_3d_magnitude(true_x, true_y, true_mag, pred_x, pred_y, pred_mag)
    return mse_x, mse_y, mse_mag, accuracy
# 添加三维柱状图
```

图 4-4 模型训练逻辑部分代码

4.3 可视化设计

本系统界面基于 LabVIEW 平台开发，旨在实现对仿生光子皮肤所采集光谱信号的实时处理与可视化，完成位置与压力的多参数预测任务。界面整体结构清晰、功能模块划分明确，便于操作者进行实时监控与参数调节，如图4-5。

左侧的二维数组显示窗口用于实时展示原始多通道光谱数据，界面下方配备了波形图模块，用于绘制输入信号的电压随时间变化曲线，便于观察信号动态特征。上方中心区域包括通道选择器，可选择多个模拟输入通道（如 Dev1/ai0 至 ai7），支持并行数据采集，适配多通道仿生传感器阵列。中部的参数设定区域允许用户自定义采样频率、模拟输入的电压范围（最小电压与最大电压）以及设备通道配置，增强了系统适应不同传感器实验需求的灵活性。

右侧绘图模块为二维定位预测结果展示区域，三个不同颜色的标记对应不同时间段的预测点，用以对比模型在时间维度上的空间预测效果。同时，系统集成预测输出区域，实时显示神经网络回归模型输出的 x 、 y 坐标与力（ T ）大小预测值。其下方配备状态指示与运行控制模块，包括运行状态指示灯、启动与停止按钮，确保了系统运行过程的可控性与安全性。



图 4-5 仿生光子皮肤定位和压力预测界面

第 5 章 系统测试与分析

5.1 传感器力学性能测试

本节重点是检查微光纤触觉传感单元测量法向力和滑动力的传感能力。该装置由8根光纤组成一个 4×4 的8通道S型传感器阵列，如图 5-1所示。




图 5-1 BPHS 实物图

在该仿生皮肤上使用精密测力仪施加静态或动态压力并识别，在BPHS上施加压力的位置和滑动方向后将压力信号转换为对光纤的压力，使其发生弯曲或形变并转换为光信号后，通过8个光纤光子通道中受影响的通道传播出去，如图 5-2所示。




图 5-2 精密测力仪在 BPHS 上施加压力时的实物图

对由两根交叉的 OMF 组成的传感单元进行了力学性能测试。在 0.5-1.2N 范围内，两个通道的压力灵敏度分别可达 0.827 N^{-1} 和 0.804 N^{-1} 。在不同压力范围内观察到的灵敏度差异可归因于传感器在较大力作用下的饱和，这导致灵敏度降低，如图 5-3 所示。




图 5-3 传感单元灵敏度测试

在加载-卸载循环测试中，传感器即使经过 700 次循环仍能保持稳定的输出，性能未出现明显下降（如图 5-4 所示）。其出色的耐用性和稳定性得益于 PDMS 中 OMF 的坚固封装以及传感器多层结构之间强大的粘附力，使其能够有效承受外部负载，并在长期使用中维持性能。该传感器具备高精度响应特性，适用于需要长时间监测外力变化的场景。此外，图中展示的输出曲线表明，传感器对不同负载变化具有优异的适应性，进一步提升了其在复杂环境下的可靠性和稳定性。




图 5-4 传感单元重复性测试

图 5-5 展示了传感器在动态力作用下的性能。分别采用 1Hz、3Hz、5Hz、8Hz、12Hz 机械振动频率的动态力对传感单元进行测试，结果表明，传感器对于滑动带来的振动具有较为准确的响应。




图 5-5 传感单元动态力响应测试

总之，本作品的传感器系统在设计、结构与性能方面表现出显著优势。它能够精准检测并持续监测外部压力变化，具备高灵敏度和优异的稳定性。得益于创新的封装工艺与多维度结构优化，该传感器可承受长期应力作用而无明显性能退化，非常适用于对稳定性和可靠性要求较高的各类应用场景。

5.2 分布式传感测试

5.2.1 空间分辨率测试

为了探究二维平面上传感器的分布式传感能力，测量了在不同位置施加不同力时，传感器输出的光强变化，如图 5-6 所示，在传感器表面分别沿 x 、 y 方向以 2mm 的步长进行力和位置的采集，每一个位置均采集了其力的大小与输出光强的关系的 300 组左右数据。在不同位置施加力时，光强出现明显变化。




图 5-6 传感器表面分布图

图 5-7 展示了在二维平面上法向力的实际值与预测值的关系及其对应的误差。力预测的平均绝对误差（MAE）为 0.015 牛顿， R^2 决定系数为 0.999。




图 5-7 力预测结果及误差

图 5-8 展示了在 4*4mm 的传感单元中，二维位置的预测与实际位置的平均绝对误差（MAE）为 0.004 毫米， R^2 决定系数接近于 1。




图 5-8 位置预测结果及误差

5.2.2 手指滑动测试

在二维平面分布式传感的测试中，传感器表现出了优异的性能。由此测试在传感器上施加滑移力并绘制图案时，传感器对其响应的特征响应。

图 5-9 展示了在传感器表面分别用手指进行向右、左、下、上、右上、左下方向滑动时，由于微光纤的纵横排列结构，输出信号表现出明显不同的特征。




图 5-9 不同方向滑移的结果

基于以上结果，我们将在传感器上进行手指滑动的测试拓展到模拟在真实人体皮肤上进行字符绘制感知，并由机器学习算法进行识别，最后在上位机上进行

预测演示，系统流程如图 5-10 所示。




图 5-10 手写字符识别示意图

为了准确预测分布式传感参数，包括沿传感器的位置及其对应力，采用了基于深度学习算法的 CNN-BiLSTM 模型，该模型包含序列转换、特征提取和预测，结果记录了400个点的数据，每个像素点采集了约300组力值与输出光强的关系。此外为评估 BPHS 在时空耦合感知及人机交互场景中的应用潜力，基于分布式微纳光纤网络的多模态信号捕获特性，构建了一套触觉驱动的手写字符加密传输原型系统。在实验中，于间距为 5 mm 的 4×4 光纤传感阵列表面动态书写数字 0–9 及字母 C、Q、U、T、P，共计 15 类字符，同步采集 8 通道光强信号（采样率 1 kHz，单样本时长 200 ms）。基于所采集的数据，设计并实现了一个端到端的 2D CNN 分类模型：网络结构包含 2 层二维卷积（滤波器数分别为 16 和 32，卷积核尺寸为 $(64, 1)$ ），结合全局最大池化进行时序特征压缩，采用 Adam 优化器（初始学习率 0.001）训练 1000 轮次。

实验共采集样本 3024 条，按 70% / 15% / 15% 划分训练集、验证集与测试集。最终模型在测试集上实现了 98.5% 的平均分类准确率。其中对于易混字符对（如“0”与“C”，“7”与“T”），系统仍保持 96.2% 和 96.0% 的识别准确率，表明 BPHS 能够有效提取并解耦相似笔画在时空维度的差异特征。系统训练预测准确率如图5-11所示。




图 5-11 训练预测准确率

通过 2D-CNN 算法对 9 个数字以及 5 个大写英文字母共计 14 个字符进行了预测，准确率达 97.20%。通过混淆图评估了分类模型性能，如图 5-12 所示。




图 5-12 字符预测混淆图

5.3 UI 功能测试

为了对本作品工作进行可视化阐述，因此开发了基于 LabVIEW 平台的触觉预测识别系统来展示。LabVIEW 通过 Python Node 调用已经训练好的 Python 机器学习模型，在 LabVIEW 环境中配置并调用已封装好的 Python 脚本，该脚本中包含训练好的机器学习模型及其预测函数。首先确保了 LabVIEW 与 Python 环境版本兼容，并正确安装了所需依赖库；然后将机器学习模型封装为可被调用

的 Python 函数；接着在 LabVIEW 中插入 Python Node，设置脚本路径和函数入口；最后通过数据输入接口将 LabVIEW 中的数据传递给 Python 函数进行预测，并接收返回结果，可以保证调用的稳定性和准确性。

在 4.3 章节中我们已经介绍了定位与压力的识别系统，该系统可以显示传感器当前实时的输出波形，实时的电压数据，以及当前按压的位置与按压的力的大小。图 5-13 展示了手写字符识别的触觉识别系统，该系统在定位与压力的识别系统的基础上增加了可以显示实时手写的字符的预测值。



图 5-13 仿生光子皮肤触觉识别系统

第 6 章 总结与规划

6.1 作品总结

本作品创新性地开发了一种基于微光纤(OMF)的仿生光子触觉皮肤(BPHS)，通过柱状微结构环绕的8通道S形微光纤阵列设计，结合Eco-flex/Dragon-skin柔性基底与PDMS封装技术，成功模拟人体皮肤的力学感知机制，解决了传统电子触觉传感器在灵敏度、抗电磁干扰及分布式感知方面的局限。传感器展现出卓越性能：力灵敏度达 0.827 N^{-1} （0–1.5N范围内单通道灵敏度 $66.08\%\text{ N}^{-1}$ ），响应时间低于50ms，动态响应覆盖1–12Hz振动频率，经700次循环加载后信号稳定性误差小于3%；同时实现多模态高精度感知，法向力分辨率达15mN，二维位置分辨率达 $4\mu\text{m}$ 。通过融合CNN-BiLSTM混合模型，系统对15类手写字符（数字0–9及字母C/Q/U/P/T）的识别准确率提升至97.20%，力与位置预测的 R^2 决定系数均超过0.999。配套开发的LabVIEW交互界面实现了光强信号、空间力分布及字符识别结果的实时可视化，验证了技术落地的可行性，并且在机器人仿生领域具有广阔的应用前景。

6.2 未来规划

未来工作将聚焦三方面突破：

（1）硬件上优化微型化封装结构以提升灵敏度，探索OMF与微流控芯片的异质集成，并扩展温/湿度多模态感知能力；

（2）算法上压缩模型参数量适配嵌入式硬件（如FPGA），引入增量学习机制动态适应用户书写特征；

（3）应用层面将植入机器人灵巧操作终端实现抓握力闭环控制，开发可穿戴式触觉反馈系统辅助医疗康复，并探索光脉冲编码机制构建光-电融合的仿生神经形态感知网络。

参考文献

- [1] 李坤. 微结构型柔性触觉传感器界面与器件性能关系 [D]; 中国科学技术大学, 2024.
- [2] ZHANG L, ZHEN Y, TONG L. Optical micro/nanofiber enabled tactile sensors and soft actuators: A review [J]. Opto-Electronic Science, 2024, 3(8): 240005-.
- [3] YAO N, WANG S. Recent progress of optical tactile sensors: A review [J]. Optics & Laser Technology, 2024, 176.
- [4] HOU L, JIANG T, YU T, et al. Tapered Optical Fiber Enabled Distributed Sensors with High Spatial Resolution by Deep Learning [J]. Advanced Optical Materials, 2024, 12(16).
- [5] LIU Z. A three-dimensionally architected electronic skin mimicking human mechanosensation [J]. Science, 2024.
- [6] 姚妮. 微纳光纤与集成光子器件耦合技术及其应用 [D]; 浙江大学, 2020.
- [7] 孔凡鑫. 微光纤谐振器温度传感 [D]; 黑龙江大学, 2023.
- [8] 黄玲. 基于微纳光纤柔性触觉传感器的盲文识别研究 [D]; 重庆理工大学, 2025.
- [9] LI W, HU Z, LI X, et al. High-sensitivity microfiber strain and force sensors [J]. Optics Communications, 2014, 314: 28-30.
- [10] HUANG L, LUO B, ZOU X, et al. Research on efficient braille recognition based on the pair-U-shaped micro-nano optical fiber fingerprint-like tactile sensors [J]. Optics & Laser Technology, 2024, 179.